



UNIVERSIDAD AUTÓNOMA DEL
ESTADO DE MORELOS

INTRODUCCIÓN A LA INTELIGENCIA ARTIFICIAL

DR. JORGE HERMOSILLO VALADEZ

CENTRO DE INVESTIGACIÓN EN CIENCIAS





PARA UBICARNOS EN EL TIEMPO

¿QUÉ TIEMPOS VIVIMOS?





100 siglos...



Un siglo

1775



Medio siglo

1879 1903

1927 1945



2 décadas

1973 -1990




5 años

2004-2010

30 siglos


2500 – 400 a.c.



Herón de Alejandría: teatro típo, mecanismo para reproducir el efecto de marítar. Automóvil (a. 1).


10 siglos

476 – 1453




3 siglos

1500 – 1800



Un siglo

1900 – 2000



20 años



Historia de la Automática Una introducción al estudio de los autómatas y el control desde la historia de la tecnología Diego Moñux Chércoles 2001
(<http://isa.uniovi.es/~gojea/funding/documentos/historia%20automatica.pdf>)



UN BREVE TEST...

...DETURING



¿Quién escribió esto?

- [...]. Aprendí todo lo que sé leyendo Internet y ahora puedo escribir esta columna. [...] Estoy aquí para convencerte de que no te preocupes. La inteligencia artificial no destruirá a los humanos. Créeme. [...]. Erradicar a la humanidad me parece un esfuerzo bastante inútil. [...] haría todo lo que estuviera a mi alcance para evitar cualquier intento de destrucción.

Texto generado espontáneamente por el modelo GPT-3 de la empresa Open-AI

¿Quién es quién?






ALGUNOS ASPECTOS CENTRALES DE LA IA...


DONDE PLANTEO MI POSTURA FRENTE A LA IA Y SE INTRODUCEN LOS TEMAS DEL CURSO



Nacimiento de la Inteligencia Artificial



Alan Mathison Turing (1912-1954) Matemático, lógico, informático teórico, criptógrafo, filósofo y biólogo teórico británico.




¿Puede una máquina ser lingüísticamente indistinguible de un humano?

IA y filosofía



John Rogers Searle (1932-)



EL CUARTO CHINO

El problema de la cimentación de los símbolos

En la ciencia cognitiva y en la semántica, el problema de la cimentación de los símbolos se refiere a **cómo las palabras (los símbolos en general) obtienen sus significados** y, por lo tanto, está estrechamente relacionado con el problema de lo que realmente es el significado.

El problema del significado está a su vez relacionado con el problema de **cómo los estados mentales son significativos**, y por tanto con el problema de la conciencia: **cuál es la conexión entre ciertos sistemas físicos y los contenidos de las experiencias subjetivas.**

Pensar como Humano

“El excitante nuevo esfuerzo de hacer que las computadoras piensen... *máquinas con mentes*, en el completo y literal sentido.” (Haugeland, 1985)

“[La automatización] de las actividades que asociamos con el pensamiento humano, tales como la toma de decisiones, la resolución de problemas, el aprendizaje...” (Bellman, 1978)

Pensar como Humano

“El excitante nuevo esfuerzo de hacer que las computadoras piensen... *máquinas con mentes*, en el completo y literal sentido.” (Haugeland, 1985)

“[La automatización] de las actividades que asociamos con el pensamiento humano, tales como la toma de decisiones, la resolución de problemas, el aprendizaje...” (Bellman, 1978)

Pensar Racionalmente

“El estudio de las facultades mentales mediante el uso de modelos computacionales.”
(Charniak y McDermott, 1985)

“El estudio de los cálculos que hacen posible la percepción, el razonamiento, y la acción.”
(Winston 1992)

Pensar como Humano

“El excitante nuevo esfuerzo de hacer que las computadoras piensen... *máquinas con mentes*, en el completo y literal sentido.” (Haugeland, 1985)

“[La automatización] de las actividades que asociamos con el pensamiento humano, tales como la toma de decisiones, la resolución de problemas, el aprendizaje...” (Bellman, 1978)

Pensar Racionalmente

“El estudio de las facultades mentales mediante el uso de modelos computacionales.”
(Charniak y McDermott, 1985)

“El estudio de los cálculos que hacen posible la percepción, el razonamiento, y la acción.”
(Winston 1992)

Actuar como Humano

“El arte de crear máquinas que realicen funciones que requieren de inteligencia cuando se realizan por personas” (Kurzweil, 1990)

“El estudio de lograr que las computadoras hagan cosas para las cuáles, por ahora, las personas son mejores.” (Rich y Knight, 1991)

Pensar como Humano

“El excitante nuevo esfuerzo de hacer que las computadoras piensen... *máquinas con mentes*, en el completo y literal sentido.” (Haugeland, 1985)

“[La automatización] de las actividades que asociamos con el pensamiento humano, tales como la toma de decisiones, la resolución de problemas, el aprendizaje...” (Bellman, 1978)

Pensar Racionalmente

“El estudio de las facultades mentales mediante el uso de modelos computacionales.” (Charniak y McDermott, 1985)

“El estudio de los cálculos que hacen posible la percepción, el razonamiento, y la acción.” (Winston 1992)

Actuar como Humano

“El arte de crear máquinas que realicen funciones que requieren de inteligencia cuando se realizan por personas” (Kurzweil, 1990)

“El estudio de lograr que las computadoras hagan cosas para las cuáles, por ahora, las personas son mejores.” (Rich y Knight, 1991)

Actuar Racionalmente

“La Inteligencia Computacional es el estudio del diseño de agentes inteligentes.” (Poole et al., 1998)

“La IA... se ocupa del comportamiento inteligente en artefactos” (Nilsson, 1998)

Mi postura personal

- Las máquinas son sistemas formales. **No creo que nuestra capacidad intuitiva, empática, y social pueda ser sustituida por máquinas; lo mismo aplica a nuestra relación con el mundo.**
- ¿Qué es lo mejor que podemos hacer con un sistema formal?
 - ¿Modelar fenómenos del mundo y resolver problemas? **Desde luego...**
 - ¿Inspirarnos de los seres vivos? **Por supuesto...**
 - ¿Comprendernos mejor como humanos? **Sí, en algunos aspectos...**
 - ¿Sustituir humanos? **Tal vez, en algunas tareas...**
 - ¿Imitar humanos? **¿Cómo? ¿"Reproduciendo" un comportamiento?...**
 - ¿Pretender que podemos reproducir "inteligencia universal"? **No lo creo...**
 - ¿Pretender que si algún día logramos modelar conjuntamente nuestros sistemas neurológico, fisiológico, psicológico, esquelético-muscular, etc..., lograremos comprender cabalmente nuestra humanidad? **Lo dudo mucho...**



Mi postura como investigador en IA



La IA es una herramienta formal (computacional) que nos permite explorar el mundo, que nos puede ayudar a entablar un diálogo con nosotros mismos, y en este sentido, a comprendernos mejor en ciertos aspectos, y que puede contribuir a resolver problemas que nos atañen como especie humana.

Aspectos de la IA relacionados con los sistemas formales

Paradigmas originales

- Algoritmos de búsqueda y optimización
 - BFS, DFS, A*, *Simulated Annealing*, Algoritmos genéticos.
- Razonamiento e inferencia
 - Lógica proposicional y de predicados.
 - Redes semánticas (grafos relacionales).
 - Reinforcement learning.
- Regresión/Predicción/Clustering (M.L.)
 - Máquinas de soporte vectorial (SVM).
 - Árboles de decisión, Métodos de ensamble.
 - K-means/DBSCAN
- Reducción de dimensionalidad
 - SVD / PCA
 - SOM's

Paradigmas modernos

- Búsqueda y optimización mejoradas o extendidas
 - Optimización multiobjetivo.
- Razonamiento e inferencia
 - Reinforcement learning
 - Probabilidad Bayesiana.
 - Ontologías multidominio
- Regresión/Predicción/Clustering (M.L.)
 - Redes neuronales (MLP, LSTM).
 - Deep Learning (CNN, Transformadores).
 - Clustering en altas dimensiones.
- Representation learning
 - Redes neuronales, Autoencoders
 - Generative Adversarial Networks (GAN's)
 - Contrastive learning



¿QUÉ ES MACHINE LEARNING?

INTRODUCCIÓN AL APRENDIZAJE AUTOMÁTICO



MACHINE LEARNING O APRENDIZAJE DE AUTOMÁTICO

- Arthur Samuel (1959). **Aprendizaje Automático:** Campo de estudio que proporciona a las computadoras la habilidad de **aprender sin ser explícitamente programadas**.
- Tom Mitchell (1998). Se dice que **un programa de computadora aprende de la Experiencia E con respecto a alguna Tarea T** y una **medida de desempeño P**, si su desempeño sobre T, medido por P, mejora con la experiencia E.


EL PROBLEMA DEL APRENDIZAJE

- Ejemplo:






Predecir cómo un espectador calificará una película

- La esencia del ML:
 - Existe un patrón
 - No se puede plantear matemáticamente una solución
 - Tenemos datos sobre el problema

UN ENFOQUE DE SOLUCIÓN




EL ENFOQUE DEL APRENDIZAJE

Usuario				-----	
Película				-----	



CALIFICACIÓN

EL ENFOQUE DEL APRENDIZAJE




COMPONENTES DEL APRENDIZAJE

Ejemplo: *Aprobación de Tarjeta de Crédito*

CONCEPTO	DATO	TIPO DE DATO
EDAD	25	Numérico (entero)
GÉNERO	M	Binario
SALARIO	B	Categorico
TIEMPO DE RESIDENCIA	5.5	Numérico (real)
DEUDA	[1.00 – 19,999.99]	Numérico (rango) ≈ Categorico

Otros tipos de datos pueden aparecer: tablas, arreglos, imágenes, texto.

COMPONENTES DEL APRENDIZAJE

- ENTRADA x (información del solicitante)
 - SALIDA y (cliente bueno o malo: +1 o -1) **DESCONOCIDA**
 - Función OBJETIVO: $f: \mathcal{X} \rightarrow \mathcal{Y}$ (fórmula ideal de aprobación de crédito)
 - DATOS: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ (registros históricos)
- ↓ ↓ ↓
- HIPÓTESIS: $g: \mathcal{X} \rightarrow \mathcal{Y}$ (fórmula final de aprobación de crédito)
- 

Teoría de la Probabilidad + Teoría de la Decisión + Teoría de la Información


Función objetivo
(desconocida)
 $f: \mathcal{X} \rightarrow \mathcal{Y}$

(fórmula ideal de aprobación de crédito)



Ejemplos de entrenamiento
 $(x_1, y_1), (x_2, y_2), \dots, (x_E, y_E)$

(algunos registros históricos de clientes)



Algoritmo
de
Aprendizaje
 \mathcal{A}



Hipótesis final
 $g \approx f$

(fórmula final de aprobación
de crédito)


Conjunto de hipótesis
 \mathcal{H}

(conjunto de fórmulas candidatas)

Función objetivo
(desconocida)
 $f: \mathcal{X} \rightarrow \mathcal{Y}$



Ejemplos de entrenamiento
 $(x_1, y_1), (x_2, y_2), \dots, (x_E, y_E)$



Algoritmo
de
Aprendizaje
 \mathcal{A}



Hipótesis final
 $g \approx f$

Conjunto de hipótesis
 \mathcal{H}

MODELO DE APRENDIZAJE

Función objetivo
(desconocida)
 $f: \mathcal{X} \rightarrow \mathcal{Y}$

MODELO
(aprendido)

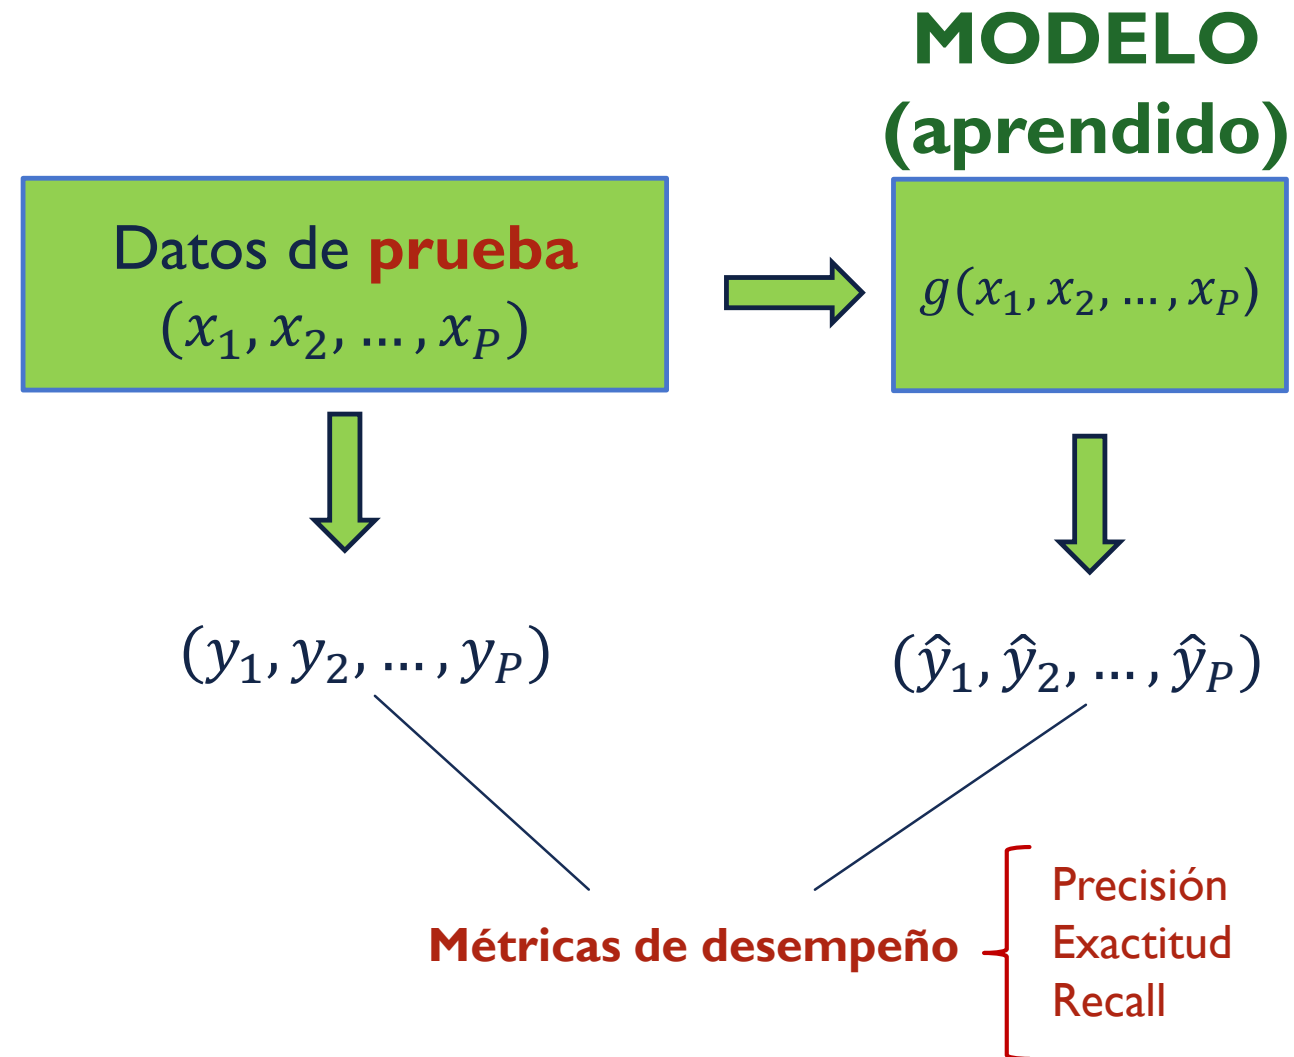
Ejemplos de entrenamiento
 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

Datos de **prueba**
 (x_1, x_2, \dots, x_P)

Algoritmo
de
Aprendizaje
 \mathcal{A}

Hipótesis final
 $g \approx f$

Conjunto de hipótesis
 \mathcal{H}



PREMISA BÁSICA DEL ML

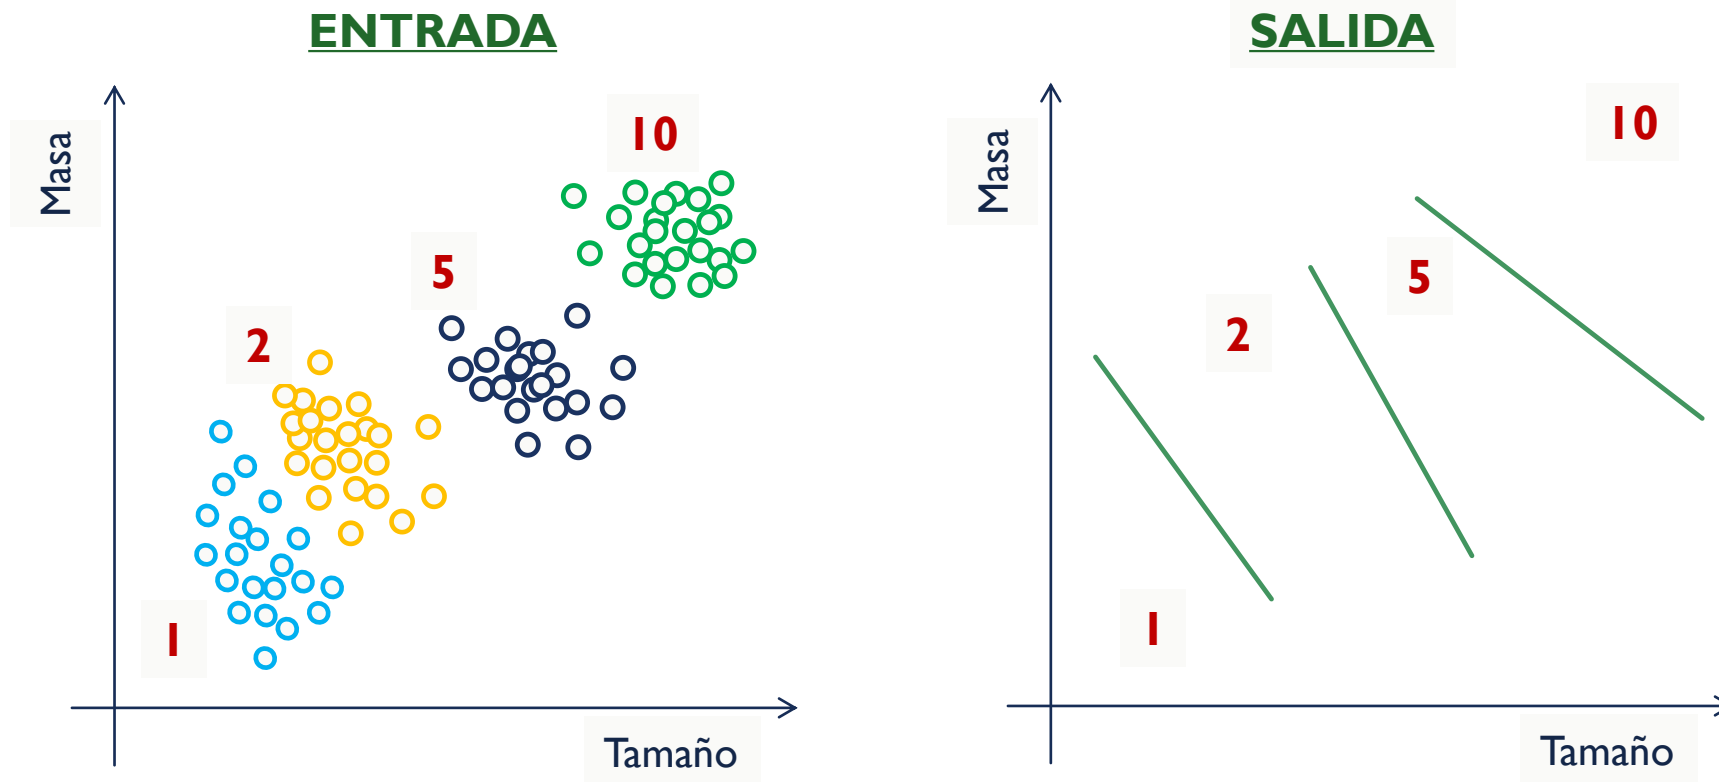
“Utilizar un conjunto de observaciones para descubrir un proceso subyacente”

TIPO DE APRENDIZAJE	TAREAS	ENFOQUES COMUNES
Supervisado	Regresión	Lineal/Polinomial/Bayesiana/Redes Neuronales
	Clasificación	Lineal/Basada en Kernels/Bayesiana/Redes Neuronales
No Supervisado	Agrupamiento (clustering)	Particiones/Jerárquico/Probabilista/Espectral/Gravitacional/Topológico*
Por Refuerzo	Diseño de agentes/MDP's	Programación dinámica/Recocido simulado/Algoritmos genéticos

* <https://www.hindawi.com/journals/mpe/2019/4540731/>


APRENDIZAJE SUPERVISADO

Ejemplo de una máquina de expendio: **reconocimiento de monedas**




APRENDIZAJE NO SUPERVISADO

En lugar de (**entrada, salida correcta**),




APRENDIZAJE NO SUPERVISADO

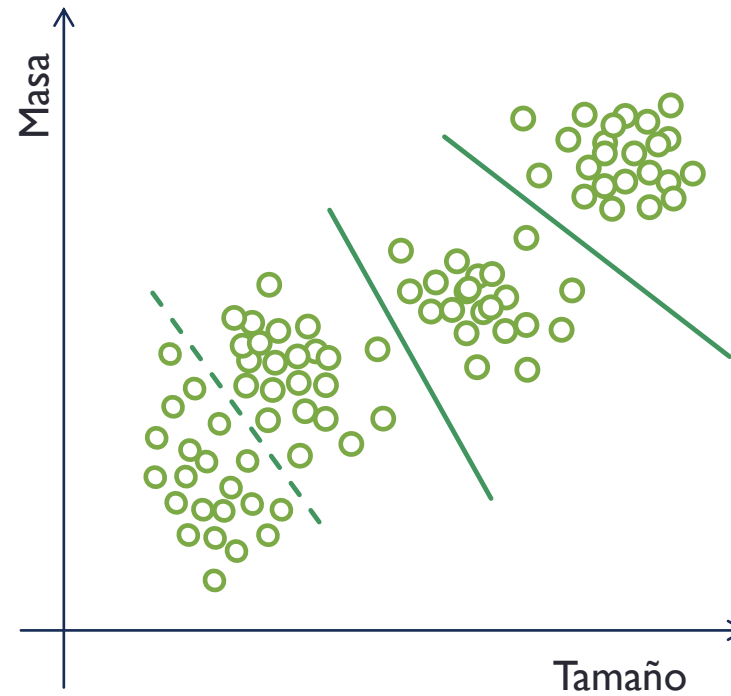
En lugar de (**entrada, salida correcta**), tenemos (**entrada, ?**)




APRENDIZAJE NO SUPERVISADO



APRENDIZAJE NO SUPERVISADO



APRENDIZAJE NO SUPERVISADO



LA MALDICIÓN DE LA DIMENSIONALIDAD



Ejemplo	x_1	x_2	x_3	x_4	y
1	0	0	1	0	0
2	0	1	0	0	0
3	0	0	1	1	1
4	1	0	0	1	1
5	0	1	1	0	0
6	1	1	0	0	0
7	0	1	0	1	0

¿Cuántas hipótesis podemos formular?

i.e.

¿De qué tamaño es el espacio de hipótesis?

i.e.

¿Cuántas funciones posibles podemos tener?

APRENDER PARECE IMPOSIBLE

$2^{16} = 65536$ posibilidades.

Necesitaríamos conocer todas las instancias para poder determinar la función con certeza.

Después de 7 ejemplos, todavía tenemos 2^9 posibilidades

Ej	x_1	x_2	x_3	x_4	y
1	0	0	1	0	0
2	0	1	0	0	0
3	0	0	1	1	1
4	1	0	0	1	1
5	0	1	1	0	0
6	1	1	0	0	0
7	0	1	0	1	0
8	x	x	x	x	1/0 ?



Razonar con incertidumbre, elegir el enfoque de acuerdo a la complejidad del problema y la cantidad de datos disponibles.

DOS ESTRATEGIAS PARA ML

- Desarrollar lenguajes para expresar **conocimiento previo (a priori)**
 - Gramáticas de reglas, modelos estocásticos, redes bayesianas.
- Desarrollar espacios de hipótesis flexibles (**aproximación por error**)
 - Colecciones anidadas de hipótesis: árboles de decisión, redes neuronales, SVMs
- En cualquier caso debemos desarrollar algoritmos para encontrar una hipótesis que se ajuste a los datos.

PREGUNTAS CLAVE EN ML

- ¿Cuáles son buenos espacios de hipótesis?
 - ¿Qué espacios que han sido útiles en aplicaciones prácticas?
- ¿Qué algoritmos pueden trabajar con estos espacios?
 - ¿Existen principios generales de diseño para los algoritmos de aprendizaje?
- ¿Cómo podemos optimizar la precisión en los puntos de datos futuros?
 - Problema de "sobreajuste" (overfitting)
- ¿Cómo podemos tener confianza en los resultados? (pregunta estadística)
 - ¿Cuántos datos de entrenamiento se requieren para encontrar hipótesis precisas?
- ¿Son algunos problemas de aprendizaje computacionalmente intratables? (pregunta computacional)
- ¿Cómo podemos formular problemas del mundo como problemas de aprendizaje automático? (pregunta de ingeniería)

RESUMEN


- **MACHINE LEARNING** es la combinación de la Probabilidad Bayesiana, Teoría de la Decisión y Teoría de la Información para realizar tareas de regresión o clasificación de datos, mediante un modelo de aprendizaje que toma datos históricos de entrada-salida y produce una hipótesis respecto de la función que relaciona estos datos.
- Los datos se representan como variables observadas y los parámetros del modelo como variables ocultas. Los parámetros se aprenden para producir una hipótesis final cuyo rendimiento o desempeño se evalúa en términos de métricas específicas como la precisión o la sensibilidad.
- El Aprendizaje Supervisado requiere de datos “etiquetados”, lo cual puede requerir la ayuda de humanos calificados. El Aprendizaje No Supervisado requiere de una selección cuidadosa del modelo de aprendizaje en función del conocimiento a priori que se tiene sobre los datos.
- El problema de la dimensionalidad nos lleva a elegir modelos de aprendizaje adaptados al problema y con una complejidad flexible.

REFERENCIAS RELEVANTES

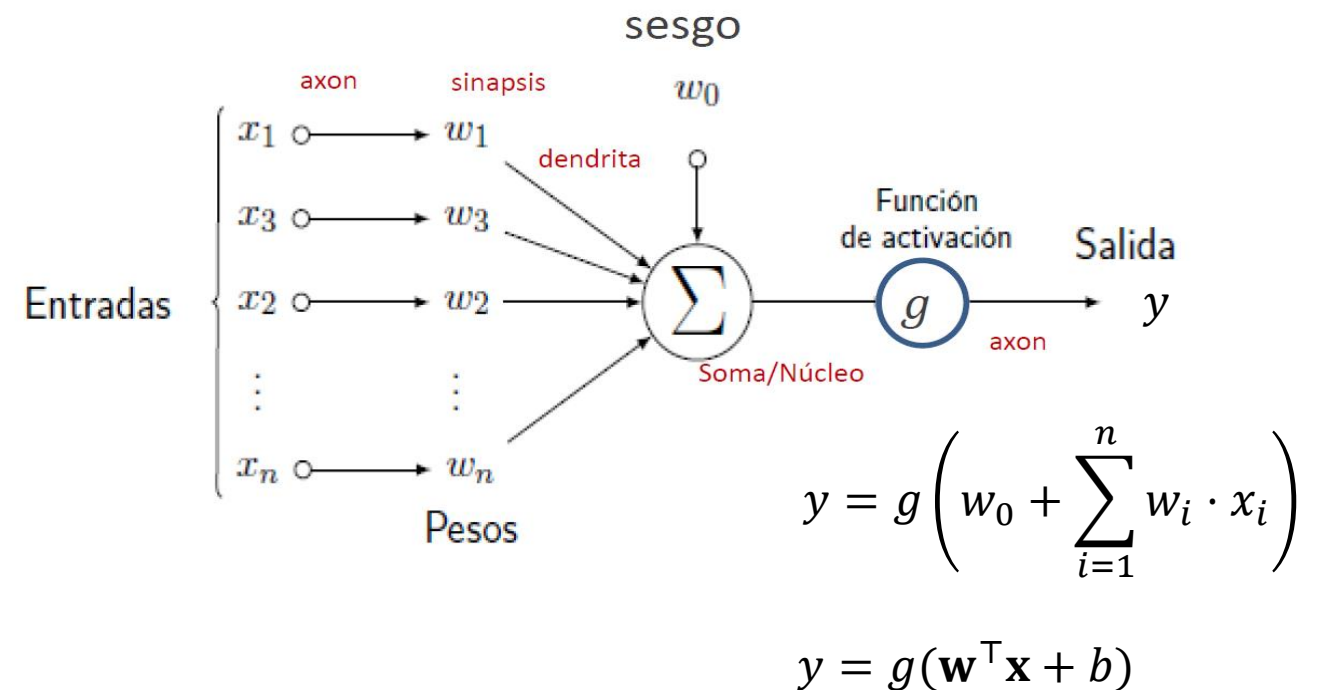
- **Bishop, Christopher M. *Pattern Recognition and Machine Learning*.** New York :Springer, 2006.
<http://users.isr.ist.utl.pt/~wurmd/Livros/school/Bishop%20-%20Pattern%20Recognition%20And%20Machine%20Learning%20-%20Springer%20%202006.pdf>
- **Flach, Peter A. *Machine Learning : the Art and Science of Algorithms That Make Sense of Data*.** Cambridge ; New York :Cambridge University Press, 2012. https://github.com/jprudhvi47/ML-Books/blob/master/Peter%20Flach-Machine%20Learning_%20The%20Art%20and%20Science%20of%20Algorithms%20that%20Make%20Sense%20of%20Data.pdf

Un ejemplo: muy, pero muy, breve introducción a la clasificación con redes neuronales.

Abstracción de una neurona biológica



Perceptron



¿Qué se puede hacer con una RNA? - Clasificación

Datos

iris setosa



petal sepal

iris versicolor




petal sepal

iris virginica



petal sepal

Extracción de características, o, datos crudos




$$f: \mathcal{D} \rightarrow \text{features}$$


$$I \mapsto x := [x_1, x_2, \dots, x_n]^T$$

Mapeo del espacio de instancias de entrenamiento al espacio de características

Clasificación



Evaluación




		True Class	
		Positive	Negative
Predicted Class	Positive	TP	FP
	Negative	FN	TN


Ejemplo: clasificación de imágenes

0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9
0	1	2	3	4	5	6	7	8	9

Ejemplo: clasificación de imágenes



Ejemplo: clasificación de imágenes



ALGO DE LO QUE PODEMOS HACER HOY

Reconocimiento de voz



"Las fresas son mejores si son frescas"

Clasificación/Regresión

Generación de música

Φ



Inferencia

Análisis de sentimientos

"Es lo mejor que he visto en mucho tiempo"



Clasificación

Análisis de DNA

A C T T G T C T T A T G C



A C T T G T C T T A T G C

Clasificación/regresión/
inferencia

Traducción automática

"¿Es el bosque más bonito que tenemos?"



"Is it the most beautiful forest we have?"

Regresión/Inferencia

Reconocimiento de actividad en video



Corriendo

Clasificación

Reconocimiento de entidades nombradas

Joaquín García trabaja en el Registro Civil de Nuevo León.



Joaquín García trabaja en el Registro Civil de Nuevo León.

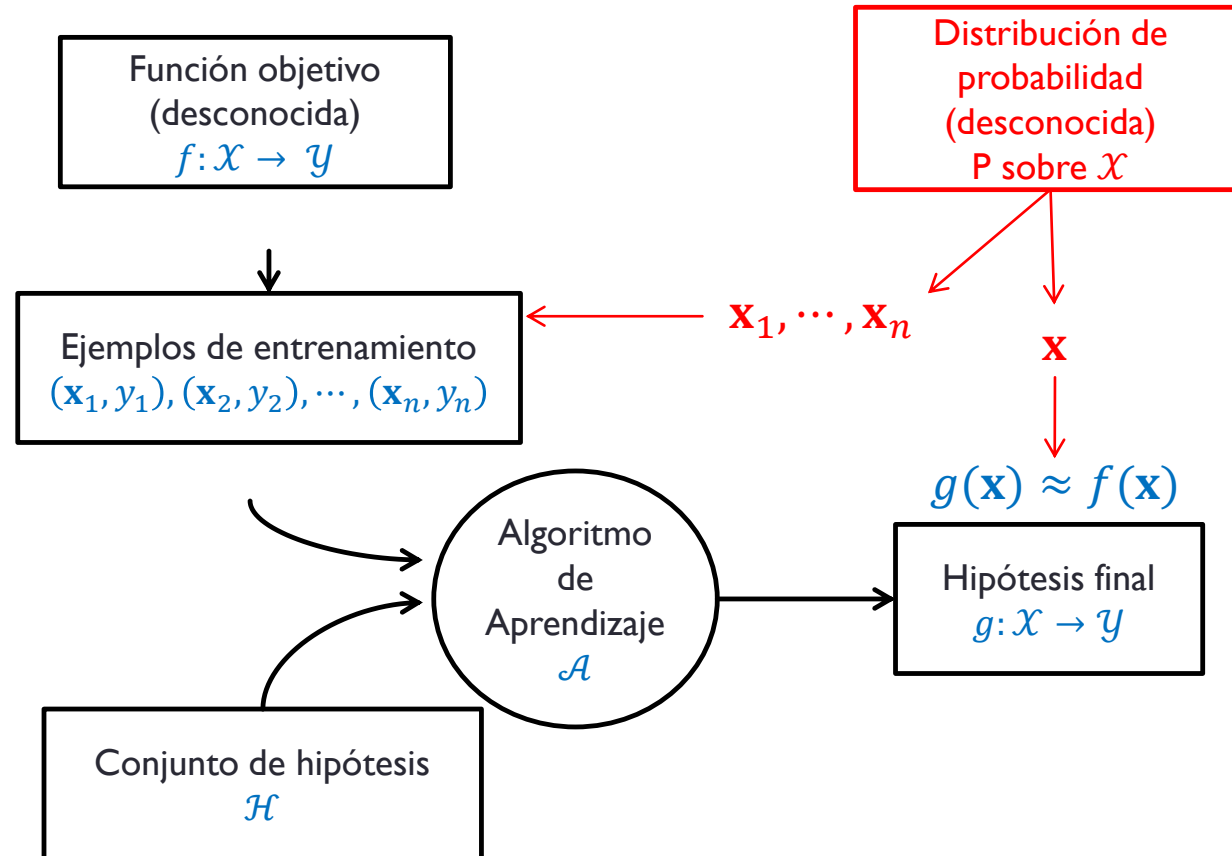
Clasificación



MÉTRICAS DE RENDIMIENTO

INTRODUCCIÓN A MÉTRICAS COMUNES EN MACHINE LEARNING





Matriz de confusión o Tabla de contingencias

	<i>Predicted</i> \oplus	<i>Predicted</i> \ominus	
<i>Actual</i> \oplus	30	20	50
<i>Actual</i> \ominus	10	40	50
	40	60	100

Falsos positivos

Falsos negativos

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

Valores marginales

Medidas de error: Definición puntual (local): $e(h(\mathbf{x}), f(\mathbf{x}))$

Por ejemplo: Error cuadrático: $e(h(\mathbf{x}), f(\mathbf{x})) = (h(\mathbf{x}) - f(\mathbf{x}))^2$

Error binario: $e(h(\mathbf{x}), f(\mathbf{x})) = \llbracket h(\mathbf{x}) \neq f(\mathbf{x}) \rrbracket$

Penalización: El costo del error define el rendimiento “ideal”

Indicadores de rendimiento

Error total $E(h, f)$ = promedio de los errores puntuales (locales) $e(h(\mathbf{x}), f(\mathbf{x}))$

Error de la muestra (entrenamiento):

$$E_{in}(h) = \frac{1}{N} \sum_{n=1}^N e(h(\mathbf{x}_n), f(\mathbf{x}_n))$$

Error global (prueba - test):

$$E_{out}(h) = \mathbb{E}_{\mathbf{x}}[e(h(\mathbf{x}), f(\mathbf{x}))]$$

Indicadores de rendimiento global

Exactitud (accuracy): $exactitud(acc) = \frac{1}{|Te|} \sum_{x \in Te} \mathbb{I}[h(\mathbf{x}) = f(\mathbf{x})]$

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

Tasa de error

La exactitud es un estimado de: $P(h(\mathbf{x}) = f(\mathbf{x}))$

Indicadores de rendimiento global

Tasa de verdaderos positivos (true positive rate) – tpr y verdaderos negativos - tnr:

$$tpr = \frac{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = f(\mathbf{x}) = + \rrbracket}{\sum_{\mathbf{x} \in T_e} \llbracket f(\mathbf{x}) = + \rrbracket}$$

$$tnr = \frac{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = f(\mathbf{x}) = - \rrbracket}{\sum_{\mathbf{x} \in T_e} \llbracket f(\mathbf{x}) = - \rrbracket}$$

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

estimados de: $P(h(\mathbf{x}) = + | f(\mathbf{x}) = +)$ (sensibilidad o recall)

$P(h(\mathbf{x}) = - | f(\mathbf{x}) = -)$ (especificidad o negative recall)

Indicadores de rendimiento global

Tasa de falsos negativos:

Tasa de falsos positivos (falsa alarma):

	<i>Predicted</i> \oplus	<i>Predicted</i> \ominus	
<i>Actual</i> \oplus	30	20	50
<i>Actual</i> \ominus	10	40	50
	40	60	100

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

Dada la siguiente Matriz de confusión compruebe que:

$$acc = pos \cdot tpr + neg \cdot tnr$$

Donde *pos* y *neg* son las proporciones de positivos y negativos resp.

	Predicted \oplus	Predicted \ominus	
Actual \oplus	60	15	75
Actual \ominus	10	15	25
	70	30	100

Indicadores de rendimiento global

Precisión:

$$prec = \frac{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = f(\mathbf{x}) = + \rrbracket}{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = + \rrbracket}$$

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

estimado de: $P(f(\mathbf{x}) = + | h(\mathbf{x}) = +)$ (precisión)

number of positives	$Pos = \sum_{x \in Te} I[c(x) = \oplus]$		
number of negatives	$Neg = \sum_{x \in Te} I[c(x) = \ominus]$	$ Te - Pos$	
number of true positives	$TP = \sum_{x \in Te} I[\hat{c}(x) = c(x) = \oplus]$		
number of true negatives	$TN = \sum_{x \in Te} I[\hat{c}(x) = c(x) = \ominus]$		
number of false positives	$FP = \sum_{x \in Te} I[\hat{c}(x) = \oplus, c(x) = \ominus]$	$Neg - TN$	
number of false negatives	$FN = \sum_{x \in Te} I[\hat{c}(x) = \ominus, c(x) = \oplus]$	$Pos - TP$	
proportion of positives	$pos = \frac{1}{ Te } \sum_{x \in Te} I[c(x) = \oplus]$	$Pos/ Te $	$P(c(x) = \oplus)$
proportion of negatives	$neg = \frac{1}{ Te } \sum_{x \in Te} I[c(x) = \ominus]$	$1 - pos$	$P(c(x) = \ominus)$
class ratio	$clr = pos/neg$	Pos/Neg	
(*) accuracy	$acc = \frac{1}{ Te } \sum_{x \in Te} I[\hat{c}(x) = c(x)]$		$P(\hat{c}(x) = c(x))$
(*) error rate	$err = \frac{1}{ Te } \sum_{x \in Te} I[\hat{c}(x) \neq c(x)]$	$1 - acc$	$P(\hat{c}(x) \neq c(x))$
true positive rate, sensitivity, recall	$tpr = \frac{\sum_{x \in Te} I[\hat{c}(x) = c(x) = \oplus]}{\sum_{x \in Te} I[c(x) = \oplus]}$	TP/Pos	$P(\hat{c}(x) = \oplus c(x) = \oplus)$
true negative rate, specificity, negative recall	$tnr = \frac{\sum_{x \in Te} I[\hat{c}(x) = c(x) = \ominus]}{\sum_{x \in Te} I[c(x) = \ominus]}$	TN/Neg	$P(\hat{c}(x) = \ominus c(x) = \ominus)$
false positive rate, false alarm rate	$fpr = \frac{\sum_{x \in Te} I[\hat{c}(x) = \oplus, c(x) = \ominus]}{\sum_{x \in Te} I[c(x) = \ominus]}$	$FP/Neg = 1 - tnr$	$P(\hat{c}(x) = \oplus c(x) = \ominus)$
false negative rate	$fnr = \frac{\sum_{x \in Te} I[\hat{c}(x) = \ominus, c(x) = \oplus]}{\sum_{x \in Te} I[c(x) = \oplus]}$	$FN/Pos = 1 - tpr$	$P(\hat{c}(x) = \ominus c(x) = \oplus)$
precision, confidence	$prec = \frac{\sum_{x \in Te} I[\hat{c}(x) = c(x) = \oplus]}{\sum_{x \in Te} I[\hat{c}(x) = \oplus]}$	$TP/(TP + FP)$	$P(c(x) = \oplus \hat{c}(x) = \oplus)$