



UNIVERSIDAD AUTÓNOMA DEL
ESTADO DE MORELOS

INTRODUCCIÓN A LA INTELIGENCIA ARTIFICIAL

DR. JORGE HERMOSILLO VALADEZ

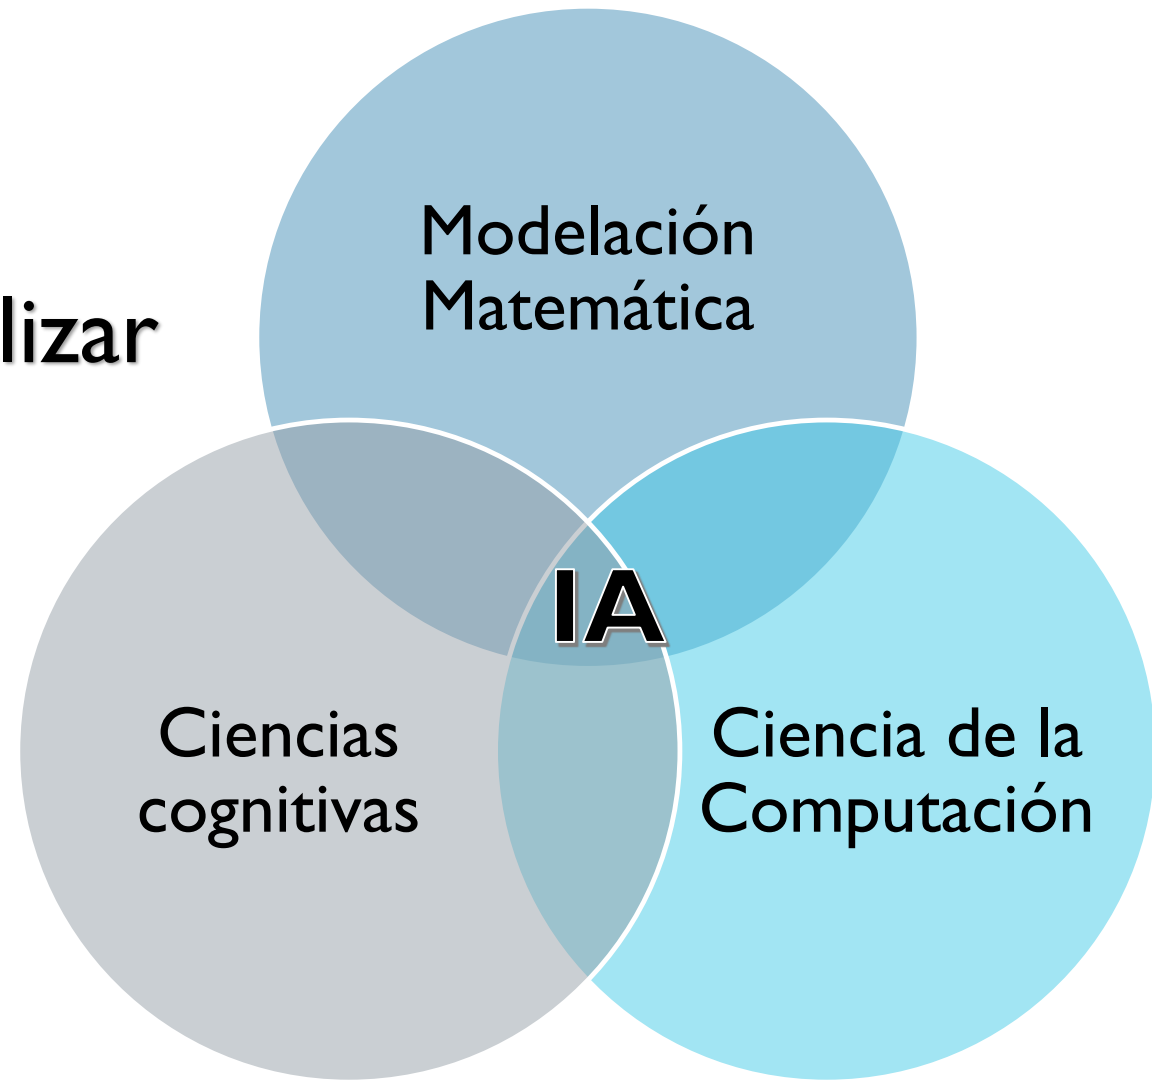
LABORATORIO DE SEMÁNTICA COMPUTACIONAL




¿QUÉ ES INTELIGENCIA ARTIFICIAL?

¿QUÉ ES LA IA?


Máquinas capaces de realizar tareas que típicamente requieren de inteligencia humana.



TEST DE TURING: 1950




Alan Turing (1912-1954)




¿Puede una máquina ser lingüísticamente indistinguible de un humano?

LA IA COMO “EXTENSIÓN” DE LA MENTE...

Idea



Redes
Neuronales



DESARROLLO EXPONENCIAL




NOCIÓN DE AGENTE

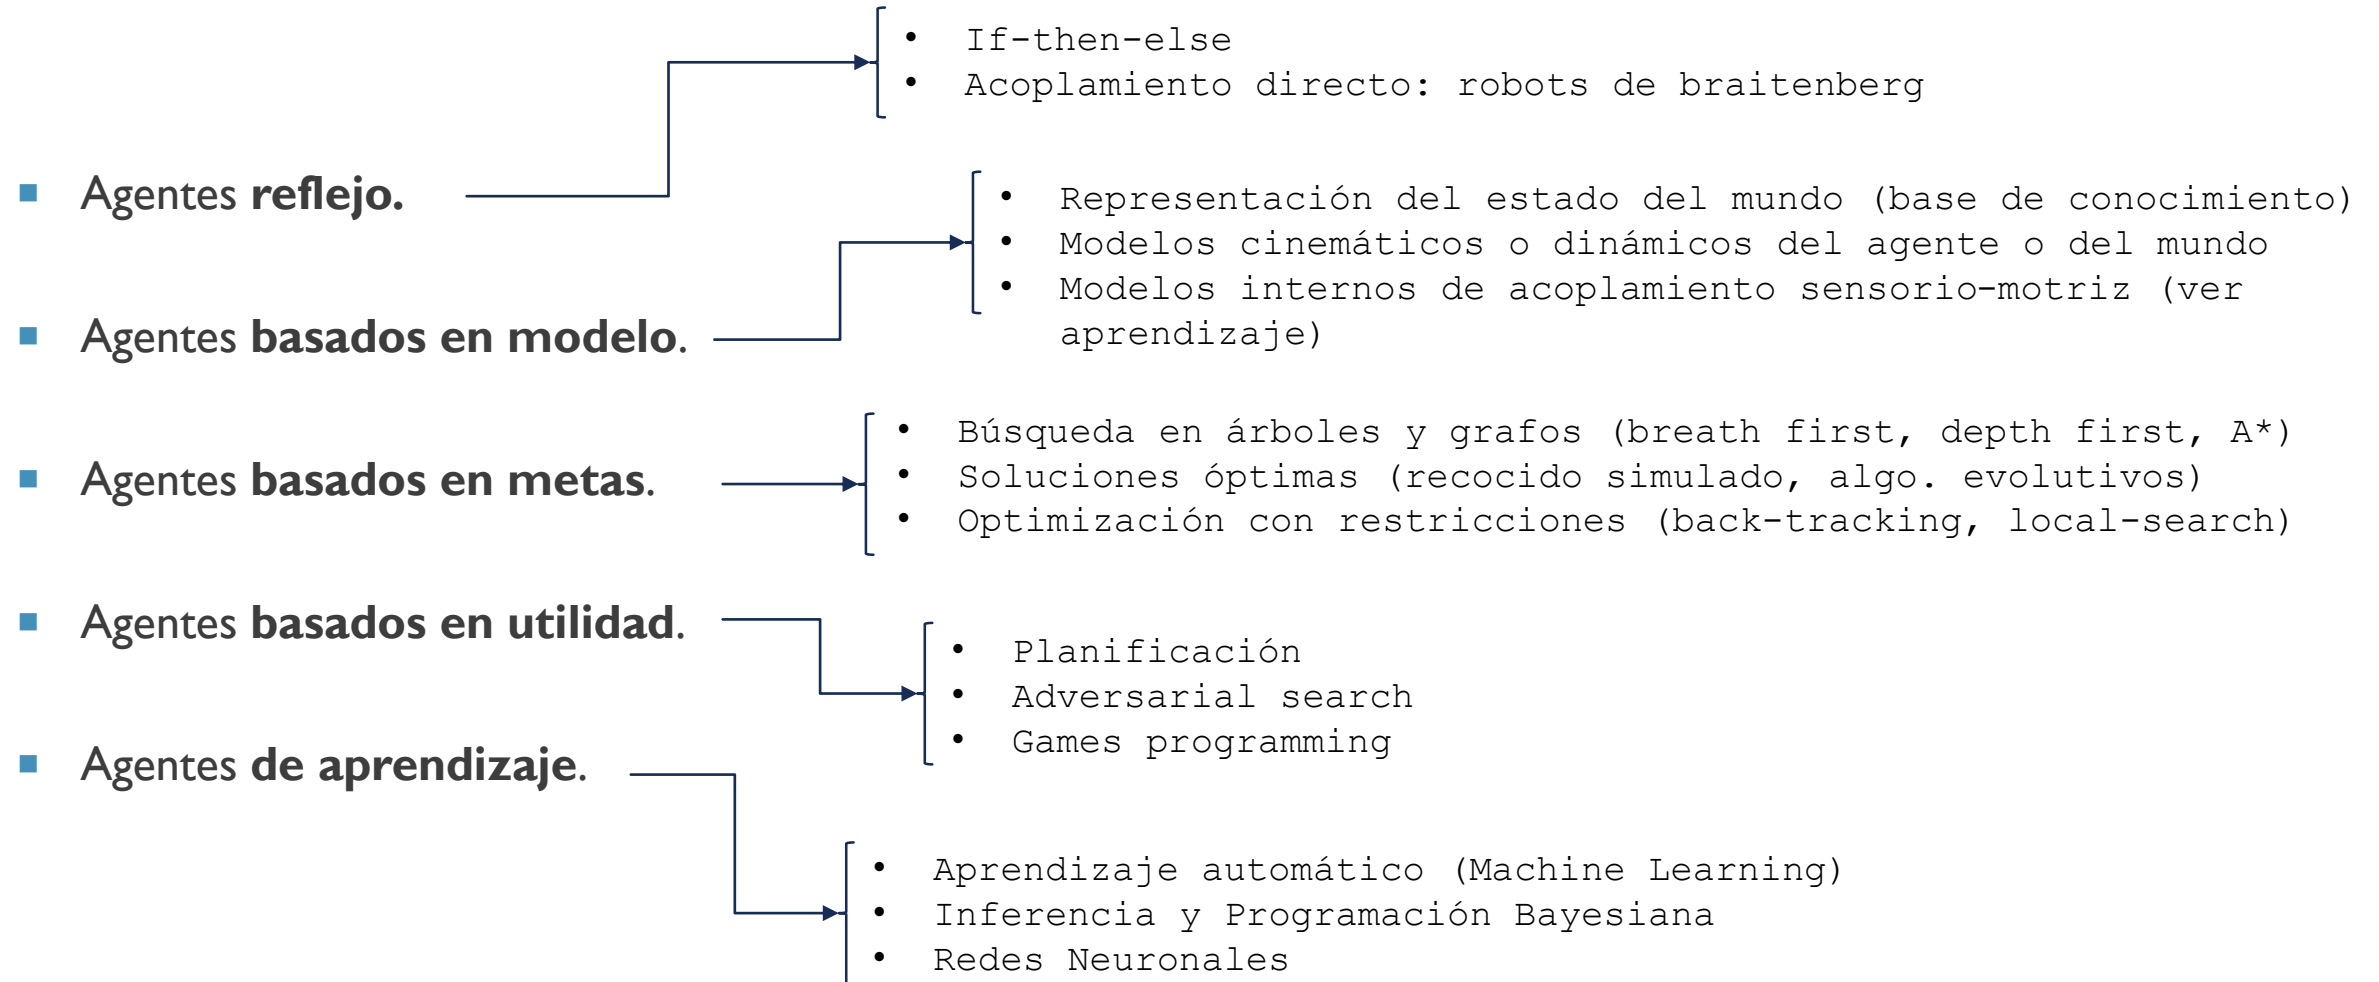
- Un AGENTE es algo que PERCIBE su ENTORNO y ACTÚA sobre éste EN FUNCIÓN de sus PERCEPCIONES.
- La **función agente** relaciona históricos de perceptos con acciones:

$$f: \mathcal{P}^* \rightarrow \mathcal{A}$$

- El **programa agente** corre en una arquitectura física para producir f



TIPOS DE AGENTE




- Razonamiento espacio-temporal.
- Adaptación situacional.
- Jerarquización de múltiples tareas.
- Autonomía.

Inteligencia
Artificial



- Razonamiento espacio-temporal.
- Adaptación situacional.
- Jerarquización de múltiples tareas.
- Autonomía.


- Small Data ($\sim 10^3$)
- Mono-dominio.
- Mono-tarea.
- Explicable.



- Razonamiento espacio-temporal.
- Adaptación situacional.
- Jerarquización de múltiples tareas.
- Autonomía.

- Small Data ($\sim 10^3$)
- Mono-dominio.
- Mono-tarea.
- Explicable.

- Medium Data ($\sim 10^6$)
- Dominio adaptable (extendible).
- Multi-tarea.
- Difícil de explicar.

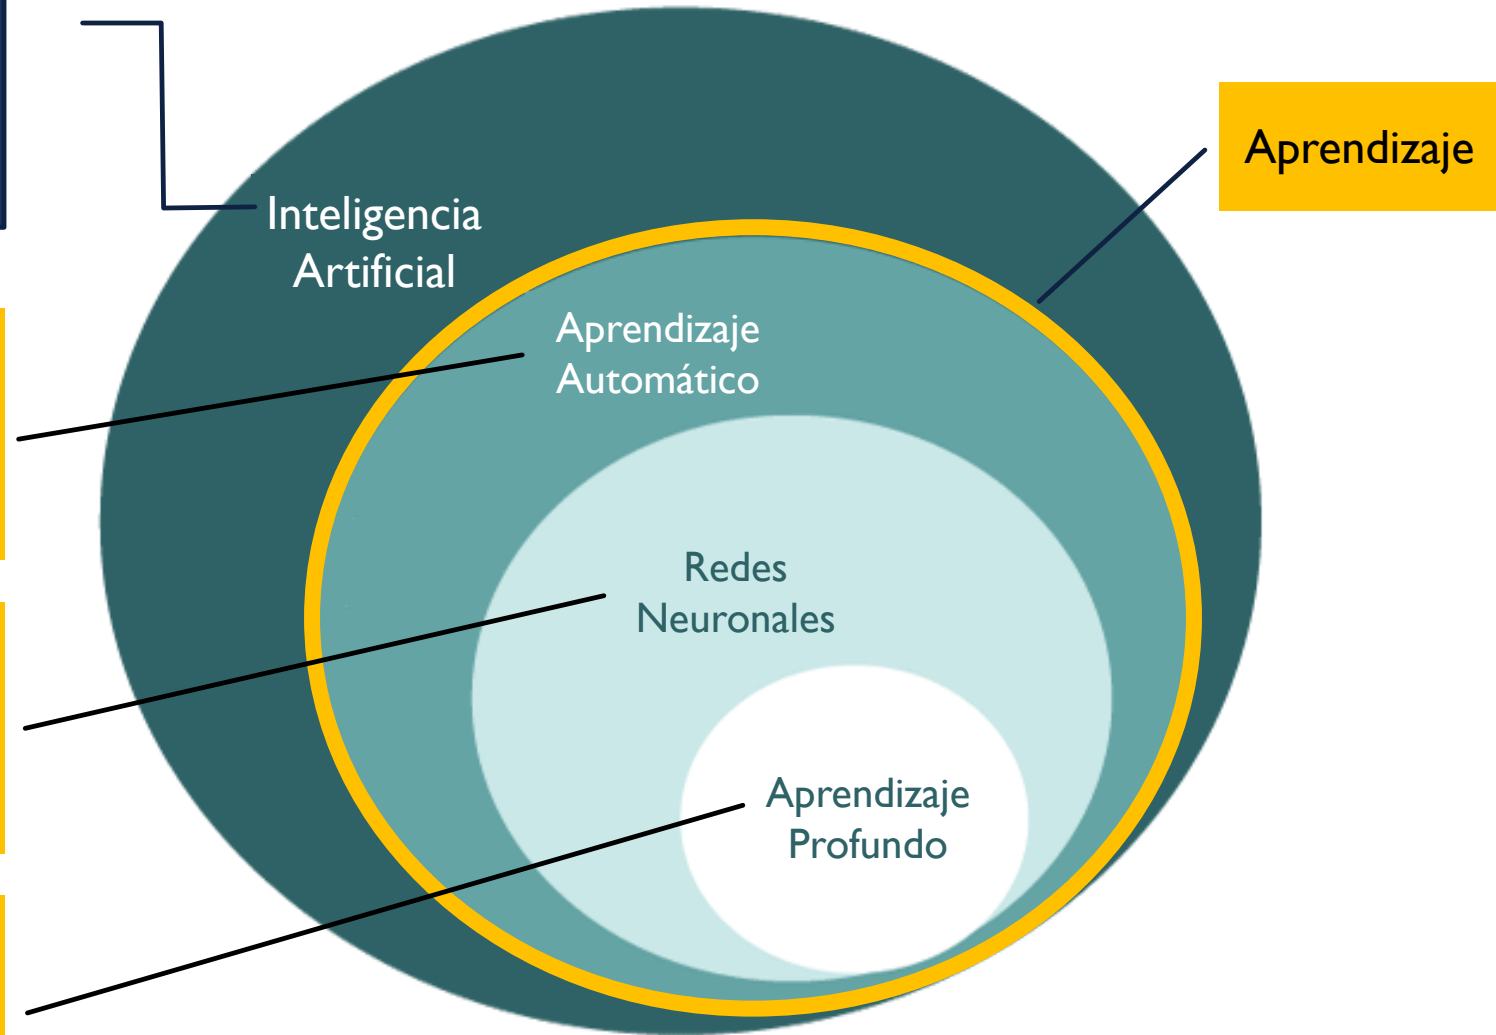


- Razonamiento espacio-temporal.
- Adaptación situacional.
- Jerarquización de múltiples tareas.
- Autonomía.

- Small Data ($\sim 10^3$)
- Mono-dominio.
- Mono-tarea.
- Explicable.

- Medium Data ($\sim 10^6$)
- Dominio adaptable (extendible).
- Multi-tarea.
- Difícil de explicar.

- Big Data ($\sim 10^9$)
- Multi-dominio.
- Multi-tarea.
- Salvo algunas excepciones, inexplicable.



ALGUNOS MÉTODOS DE IA, ML Y DL

- Algoritmos de búsqueda y optimización
 - BFS, DFS, A*, *Simulated Annealing*, Algoritmos genéticos.
 - Optimización multiobjetivo
- Razonamiento e inferencia
 - Lógica proposicional y de predicados.
 - Probabilidad Bayesiana
 - Redes semánticas (grafos relacionales).
- Métodos supervisados de M.L.
 - Regresión lineal
 - Regresión logística
 - Máquinas de soporte vectorial (SVM).
 - Naïve Bayes
 - Árboles de decisión, Métodos de ensemble.
- Reducción de dimensionalidad
 - SVD / PCA
 - TSNE, UMAP
- Aprendizaje por refuerzo
- Clustering
 - K-means
 - DBSCAN
 - Spectral clustering
- Métodos supervisados de Deep Learning
 - Perceptron Multicapa (feed forward network).
 - Redes de Convolución (CNN).
 - Redes Recurrentes (LSTM).
 - Generative Adversarial Networks (GAN's)
 - Redes Siamesas
 - Transformadores
- Métodos semi o no supervisados de Deep learning
 - Autoencoders
 - Contrastive learning

ALGUNAS APLICACIONES DE IA, ML Y DL

- Visión por computadora
 - Detección.
 - Reconocimiento.
 - Segmentación.
- Procesamiento de Lenguaje Natural.
 - Lectura, comprensión y producción de textos.
 - Resúmenes automáticos.
 - Reconocimiento/Reproducción de voz.
 - Análisis de sentimientos.
 - Atribución y perfilado de autores.
 - Chatbots.
- Robótica
 - Localización.
 - Planificación.
 - Navegación.
- Modelación numérica
 - Procesos industriales.
 - Sistemas dinámicos.
 - Aproximación de funciones.
- Análisis de series de tiempo
 - Fenómenos migratorios.
 - Estudios epidemiológicos.
 - Datos fisiológicos.
 - Finanzas.





ALGUNAS TAREAS EN IA

REGRESIÓN

Predicción de:

- Valores numéricos (temperatura, flujo, masa, tiempo, ubicación, ...)
- Representaciones numéricas de: palabras, imágenes, voz, música, ...

¿Qué valor predice un nuevo dato?





CLASIFICACIÓN

Predicción de:

- Etiquetas (clases, categorías)

¿A qué clase pertenece un nuevo dato?

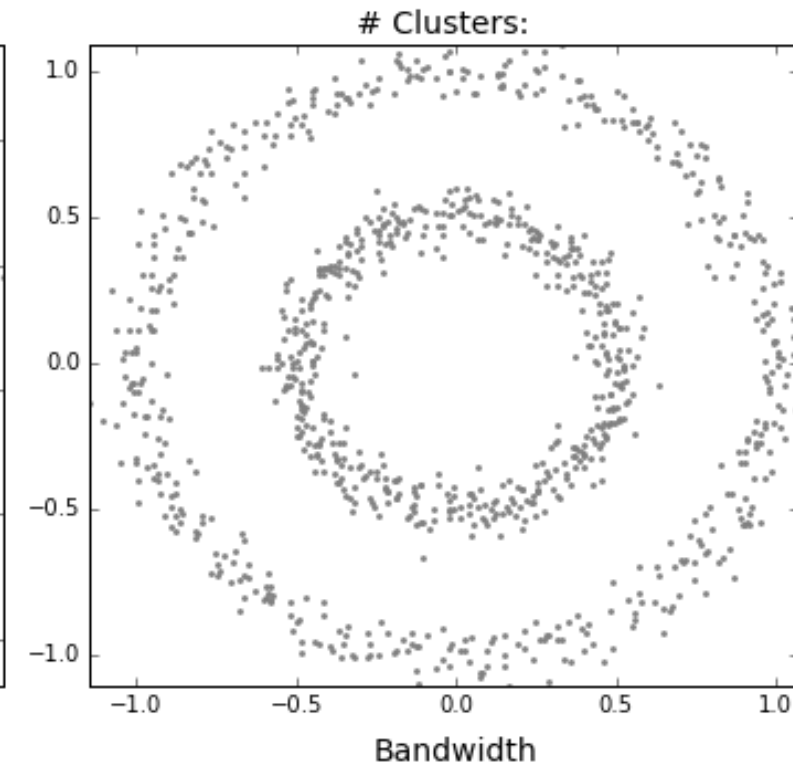
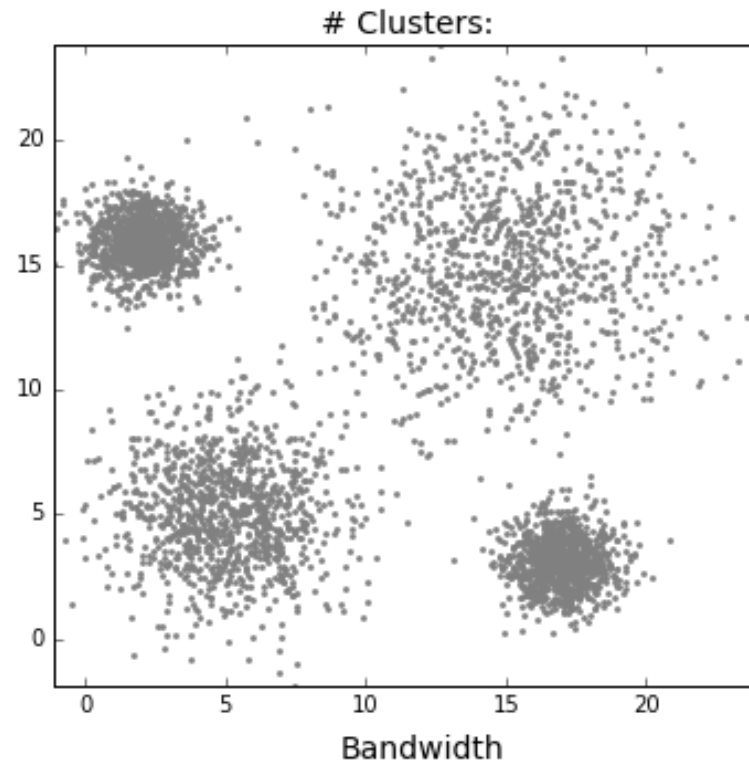



CLUSTERING

Predicción de:

- Grupos de objetos asociados por algún tipo de similitud (distancia o correlación entre características)

¿Qué datos se parecen entre sí?





¿QUÉ ES MACHINE LEARNING?

INTRODUCCIÓN AL APRENDIZAJE AUTOMÁTICO

MACHINE LEARNING O APRENDIZAJE DE AUTOMÁTICO

- Arthur Samuel (1959). **Aprendizaje Automático:** Campo de estudio que proporciona a las computadoras la habilidad de **aprender sin ser explícitamente programadas**.
- Tom Mitchell (1998). Se dice que **un programa de computadora aprende de la Experiencia E con respecto a alguna Tarea T** y una **medida de desempeño P**, si su desempeño sobre T, medido por P, mejora con la experiencia E.

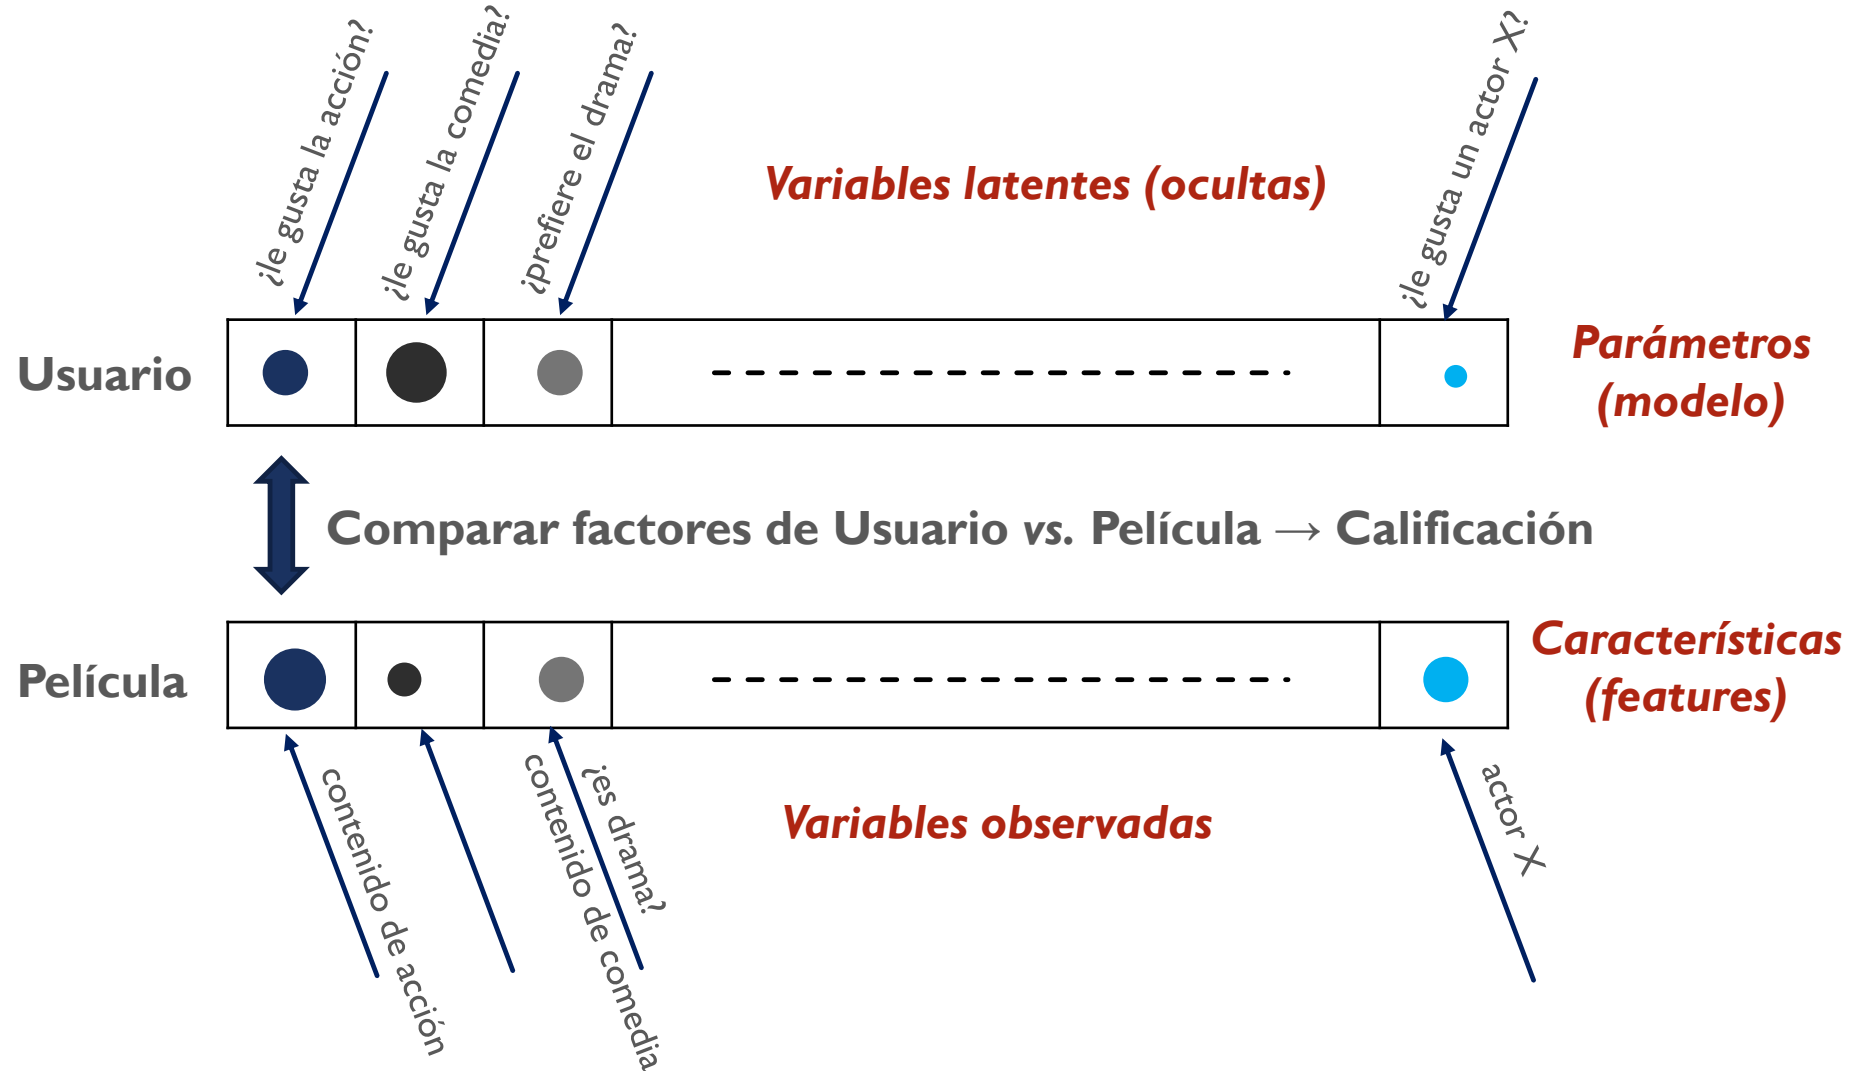
EL PROBLEMA DEL APRENDIZAJE

- Ejemplo:








Predecir cómo un espectador calificará una película

- La esencia del ML:
 - Existe un patrón
 - No se puede plantear matemáticamente una solución
 - Tenemos datos sobre el problema

UN ENFOQUE DE SOLUCIÓN




EL ENFOQUE DEL APRENDIZAJE

Usuario				-----	
Película				-----	



CALIFICACIÓN

EL ENFOQUE DEL APRENDIZAJE



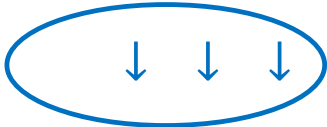

COMPONENTES DEL APRENDIZAJE

Ejemplo: *Aprobación de Tarjeta de Crédito*

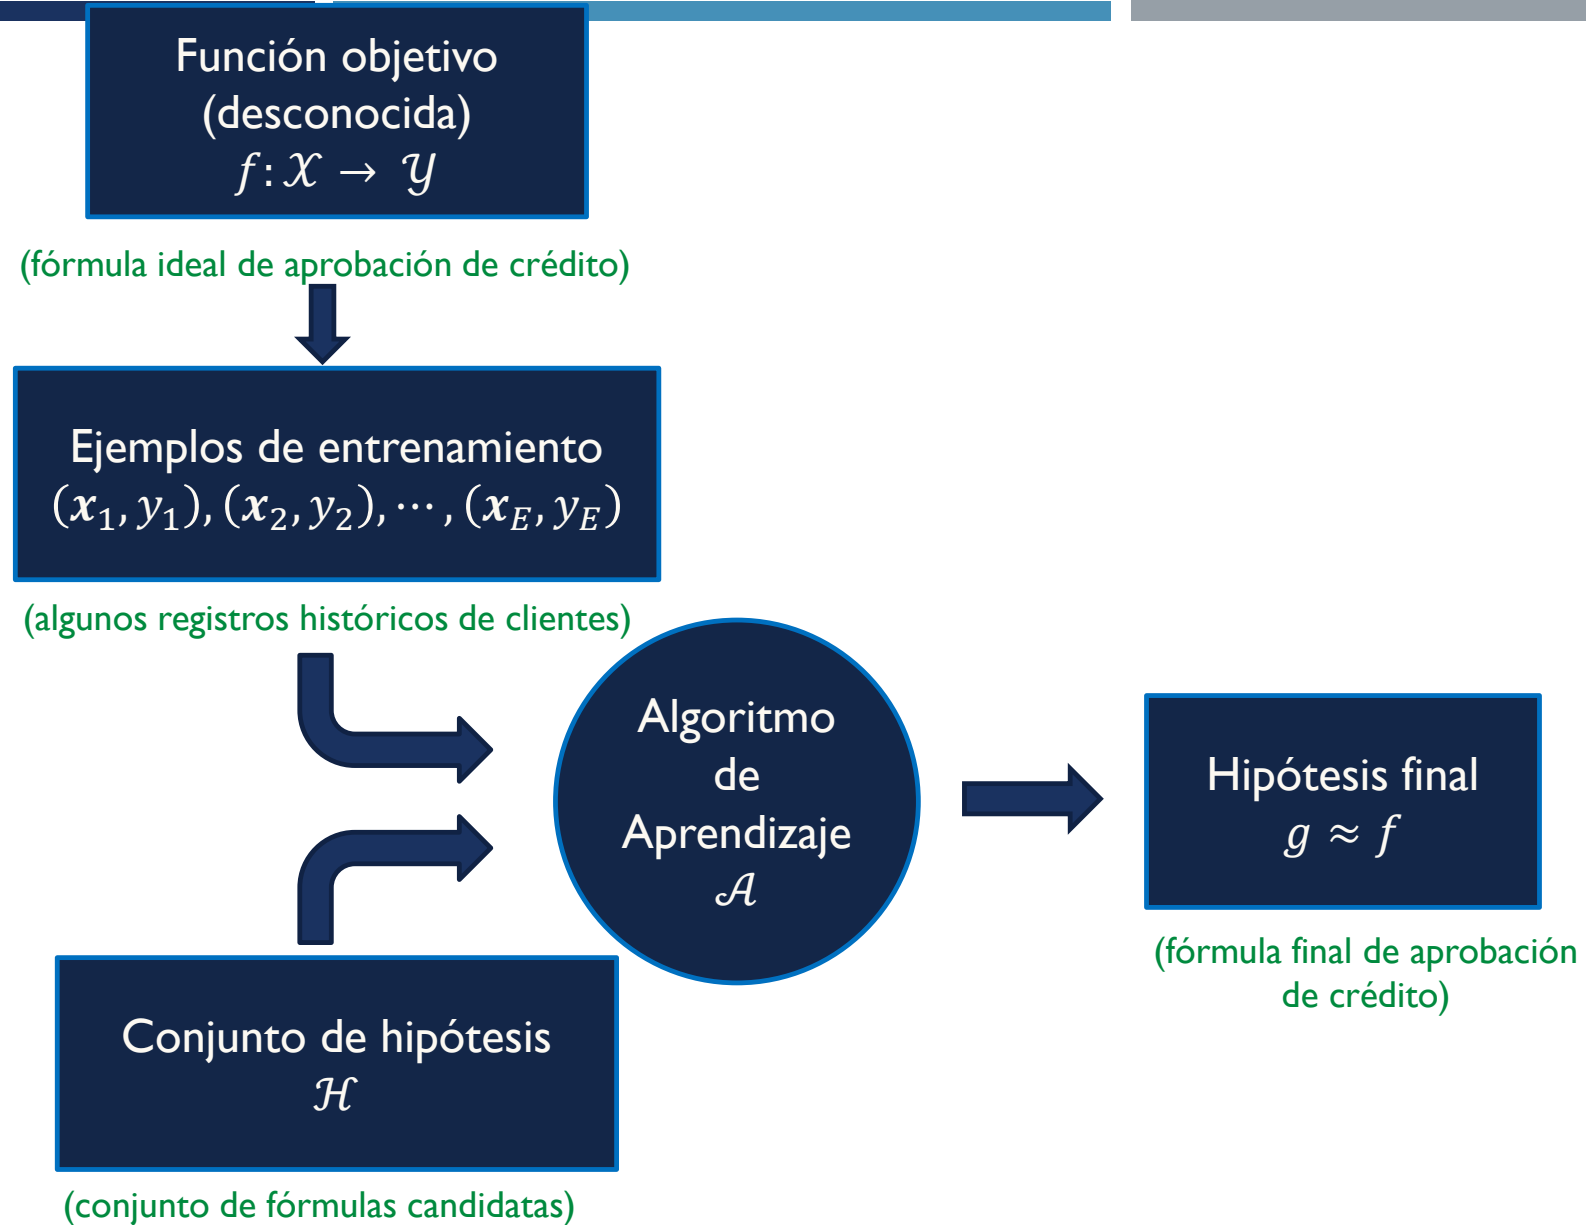
CONCEPTO	DATO	TIPO DE DATO
EDAD	25	Numérico (entero)
GÉNERO	M	Binario
SALARIO	B	Categorico
TIEMPO DE RESIDENCIA	5.5	Numérico (real)
DEUDA	[1.00 – 19,999.99]	Numérico (rango) ≈ Categorico

Otros tipos de datos pueden aparecer: tablas, arreglos, imágenes, texto.

COMPONENTES DEL APRENDIZAJE

- ENTRADA x (información del solicitante)
 - SALIDA y (cliente bueno o malo: +1 o -1) **DESCONOCIDA**
 - Función OBJETIVO: $f: \mathcal{X} \rightarrow \mathcal{Y}$ (fórmula ideal de aprobación de crédito)
 - DATOS: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ (registros históricos)
- 
- HIPÓTESIS: $g: \mathcal{X} \rightarrow \mathcal{Y}$ (fórmula final de aprobación de crédito)
- 


Teoría de la Probabilidad + Teoría de la Decisión + Teoría de la Información



Función objetivo
(desconocida)
 $f: \mathcal{X} \rightarrow \mathcal{Y}$



Ejemplos de entrenamiento
 $(x_1, y_1), (x_2, y_2), \dots, (x_E, y_E)$



Algoritmo
de
Aprendizaje
 \mathcal{A}



Hipótesis final
 $g \approx f$

Conjunto de hipótesis
 \mathcal{H}

MODELO DE APRENDIZAJE

Función objetivo
(desconocida)
 $f: \mathcal{X} \rightarrow \mathcal{Y}$

MODELO
(aprendido)

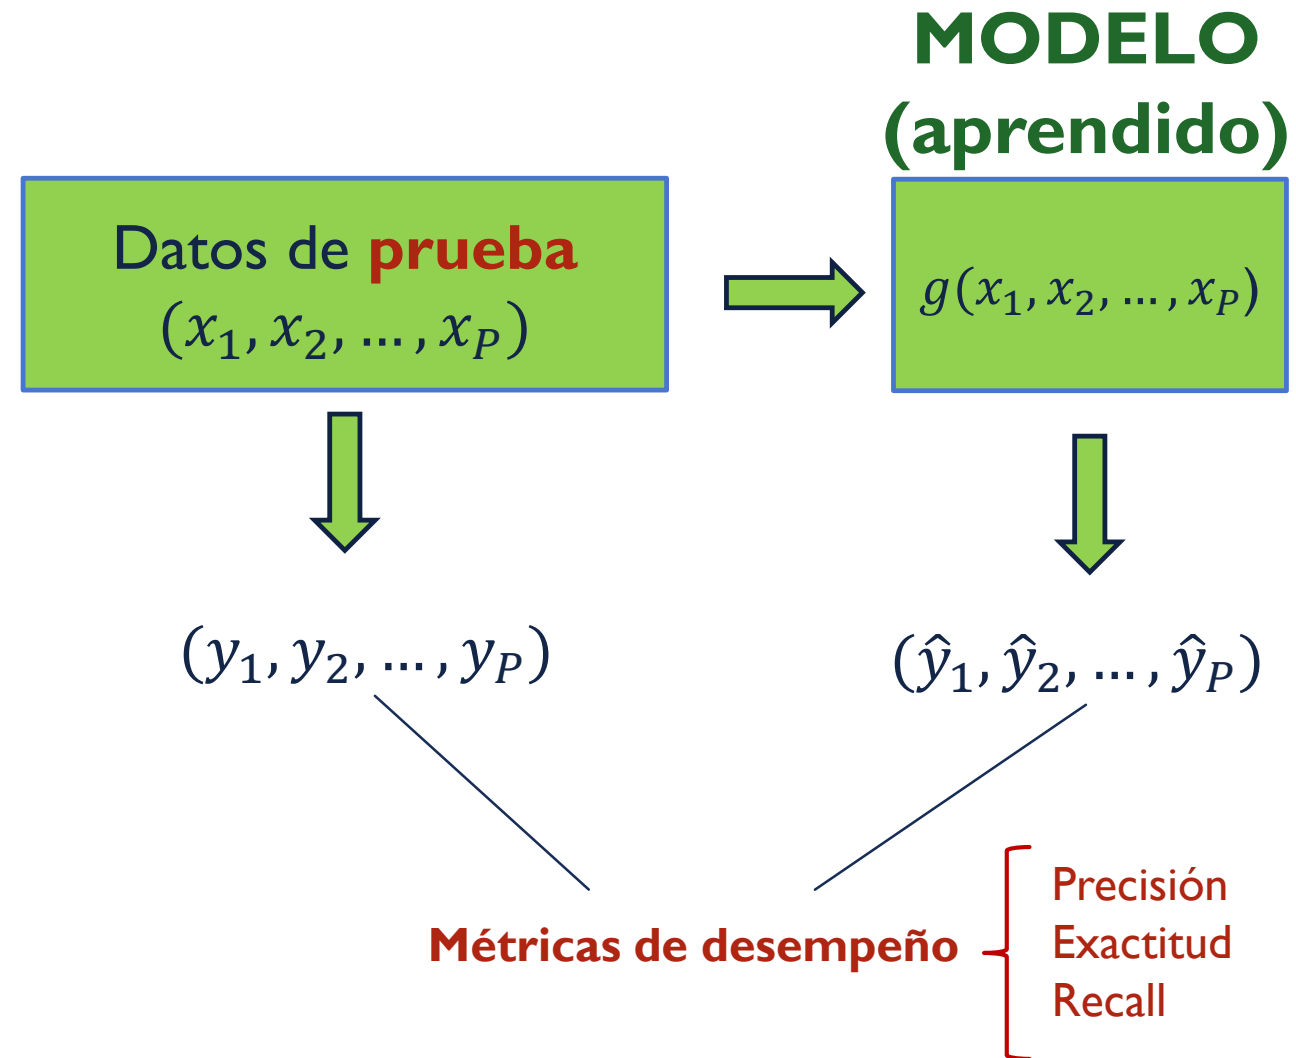
Ejemplos de entrenamiento
 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

Datos de **prueba**
 (x_1, x_2, \dots, x_P)


Algoritmo
de
Aprendizaje
 \mathcal{A}

Hipótesis final
 $g \approx f$

Conjunto de hipótesis
 \mathcal{H}



LA MALDICIÓN DE LA DIMENSIONALIDAD



Ejemplo	x_1	x_2	x_3	x_4	y
1	0	0	1	0	0
2	0	1	0	0	0
3	0	0	1	1	1
4	1	0	0	1	1
5	0	1	1	0	0
6	1	1	0	0	0
7	0	1	0	1	0

¿Cuántas hipótesis podemos formular?

i.e.

¿De qué tamaño es el espacio de hipótesis?

i.e.

¿Cuántas funciones posibles podemos tener?

APRENDER PARECE IMPOSIBLE

$2^{16} = 65536$ posibilidades.

Necesitaríamos conocer todas las instancias para poder determinar la función con certeza.

Después de 7 ejemplos, todavía tenemos 2^9 posibilidades

Ej	x_1	x_2	x_3	x_4	y
1	0	0	1	0	0
2	0	1	0	0	0
3	0	0	1	1	1
4	1	0	0	1	1
5	0	1	1	0	0
6	1	1	0	0	0
7	0	1	0	1	0
8	x	x	x	x	1/0 ?



Razonar con incertidumbre, elegir el enfoque de acuerdo a la complejidad del problema y la cantidad de datos disponibles.

DOS ESTRATEGIAS PARA ML

- Desarrollar lenguajes para expresar **conocimiento previo (a priori)**
 - Gramáticas de reglas, modelos estocásticos, redes bayesianas.
- Desarrollar espacios de hipótesis flexibles (**aproximación por error**)
 - Colecciones anidadas de hipótesis: árboles de decisión, redes neuronales, SVMs
- En cualquier caso debemos desarrollar algoritmos para encontrar una hipótesis que se ajuste a los datos.

PREGUNTAS CLAVE EN ML

- ¿Cuáles son buenos espacios de hipótesis?
 - ¿Qué espacios que han sido útiles en aplicaciones prácticas?
- ¿Qué algoritmos pueden trabajar con estos espacios?
 - ¿Existen principios generales de diseño para los algoritmos de aprendizaje?
- ¿Cómo podemos optimizar la precisión en los puntos de datos futuros?
 - Problema de "sobreajuste" (overfitting)
- ¿Cómo podemos tener confianza en los resultados? (pregunta estadística)
 - ¿Cuántos datos de entrenamiento se requieren para encontrar hipótesis precisas?
- ¿Son algunos problemas de aprendizaje computacionalmente intratables? (pregunta computacional)
- ¿Cómo podemos formular problemas del mundo como problemas de aprendizaje automático? (pregunta de ingeniería)

RESUMEN

- **MACHINE LEARNING** es la combinación de la Probabilidad Bayesiana, Teoría de la Decisión y Teoría de la Información para realizar tareas de regresión o clasificación de datos, mediante un modelo de aprendizaje que toma datos históricos de entrada-salida y produce una hipótesis respecto de la función que relaciona estos datos.
- Los datos se representan como variables observadas y los parámetros del modelo como variables ocultas. Los parámetros se aprenden para producir una hipótesis final cuyo rendimiento o desempeño se evalúa en términos de métricas específicas como la precisión o la sensibilidad.
- El Aprendizaje Supervisado requiere de datos “etiquetados”, lo cual puede requerir la ayuda de humanos calificados. El Aprendizaje No Supervisado requiere de una selección cuidadosa del modelo de aprendizaje en función del conocimiento a priori que se tiene sobre los datos.
- El problema de la dimensionalidad nos lleva a elegir modelos de aprendizaje adaptados al problema y con una complejidad flexible.


REFERENCIAS RELEVANTES

- **Flach, Peter A. *Machine Learning : the Art and Science of Algorithms That Make Sense of Data*.** Cambridge; New York :Cambridge University Press, 2012.
- **Bishop, Christopher M. *Pattern Recognition and Machine Learning*.** New York :Springer, 2006.



MÉTRICAS DE RENDIMIENTO

INTRODUCCIÓN A MÉTRICAS COMUNES EN MACHINE LEARNING



EVALUACIÓN DEL RENDIMIENTO

Matriz de confusión o Tabla de contingencias

Verdaderos positivos (TP) Aciertos

$$TP = \sum_{x \in Te} \mathbb{I}[h(x) = f(x) = \oplus]$$

Falsos negativos (FN)

$$FN = \sum_{x \in Te} \mathbb{I}[h(x) = \ominus, f(x) = \oplus]$$

Error tipo II
(omisión, subestimación)

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

	\oplus	\ominus	
\oplus	20	30	50
\ominus	20	30	50
	40	60	100

P número total de \oplus

N número total de \ominus

Valores marginales

Falsos positivos (FP)

Verdaderos Negativos (TN)

Rechazos correctos

$$FP = \sum_{x \in Te} \mathbb{I}[h(x) = \oplus, f(x) = \ominus]$$

$$TN = \sum_{x \in Te} \mathbb{I}[h(x) = f(x) = \ominus]$$

Error tipo I
(falsa alarma, sobreestimación)

INDICADORES DE RENDIMIENTO GLOBAL

Exactitud (accuracy) $\frac{TP + TN}{P + N}$

$$acc = \frac{1}{|Te|} \sum_{x \in Te} \mathbb{I}[f(x) = h(x)] \quad P(h(\mathbf{x}) = f(\mathbf{x}))$$

	÷		
	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

Diagram illustrating the calculation of Accuracy (acc) using the confusion matrix. The matrix shows counts for Actual vs Predicted classes (\oplus and \ominus). The total number of samples is 100. The number of correct predictions (TP + TN) is 50 (30 TP + 20 TN). The accuracy is calculated as $\frac{50}{100} = 0.5$.

Sensibilidad (Recall) $\frac{TP}{P}$
True Positive Rate (TPR)

$$tpr = \frac{\sum_{\mathbf{x} \in Te} \mathbb{I}[h(\mathbf{x}) = f(\mathbf{x}) = +]}{\sum_{\mathbf{x} \in Te} \mathbb{I}[f(\mathbf{x}) = +]}$$

$$P(h(\mathbf{x}) = + | f(\mathbf{x}) = +)$$

INDICADORES DE RENDIMIENTO GLOBAL

Precisión $\frac{TP}{TP + FP}$

$$prec = \frac{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = f(\mathbf{x}) = + \rrbracket}{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = + \rrbracket}$$

$$P(f(\mathbf{x}) = + | h(\mathbf{x}) = +)$$

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

Diagram illustrating the calculation of Precision and Recall from the confusion matrix:

- Precision: $\frac{30}{30 + 10} = \frac{30}{40} = 75\%$
- Recall: $\frac{30}{30 + 20} = \frac{30}{50} = 60\%$

$$accuracy = 70\%$$

$$recall = 60\%$$

$$precision = 75\%$$

$$F_1 = 66\%$$

$$F_1 = \frac{2TP}{2TP + FP + FN}$$

$$F_1 = 2 \frac{precision \cdot recall}{precision + recall}$$

INDICADORES DE RENDIMIENTO GLOBAL

Precisión $\frac{TP}{TP + FP}$

$$prec = \frac{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = f(\mathbf{x}) = + \rrbracket}{\sum_{\mathbf{x} \in T_e} \llbracket h(\mathbf{x}) = + \rrbracket}$$

$$P(f(\mathbf{x}) = + | h(\mathbf{x}) = +)$$

	Predicted \oplus	Predicted \ominus	
Actual \oplus	30	20	50
Actual \ominus	10	40	50
	40	60	100

Diagram illustrating the calculation of Precision and Recall from the confusion matrix:

- Precision: $\frac{30}{30 + 10} = \frac{30}{40} = 75\%$
- Recall: $\frac{30}{30 + 20} = \frac{30}{50} = 60\%$

$$accuracy = 70\%$$

$$recall = 60\%$$


$$precision = 75\%$$

$$F_1 = 66\%$$

$$F_1 = \frac{2TP}{2TP + FP + FN}$$

$$F_1 = 2 \frac{precision \cdot recall}{precision + recall}$$

EFFECTO DEL DESBALANCE DE CLASES



Supongamos que de cada 10,000 imágenes sólo 100 presentan casos de cáncer de pulmón

Si tu modelo predice que todas las imágenes presentan casos sanos, tu matriz de confusión se vería así:





	$h(x) = \oplus$	$h(x) = \ominus$	
$f(x) = \oplus$	0	100	100
$f(x) = \ominus$	0	9,900	9,900
	0	10,000	

!!! La exactitud (acc) sería del 99% !!!

Mejor usar precisión, recall, F1 o ROC

AUC-ROC

- AUC-ROC es una métrica utilizada para evaluar el rendimiento de un modelo de clasificación. AUC significa "Área bajo la curva" y ROC significa "Característica de funcionamiento del receptor".
- La curva ROC es un gráfico que muestra el rendimiento de un modelo de clasificación en todos los umbrales de clasificación. El puntaje AUC-ROC es el área bajo la curva ROC y nos da una buena idea de qué tan bien funciona el modelo. Cuanto mayor sea el puntaje AUC-ROC, mejor será el rendimiento del modelo.



Fuentes:

- [Understanding AUC - ROC Curve.](#) Sarang Narkhede. Towards Data Science.
- [Guide to AUC ROC Curve in Machine Learning :What Is Specificity?](#) Aniruddha Bhandari Analytics Vidya